

ИТМО Университет

Факультет прикладной математики и
компьютерных наук

Лабораторная работа по математической статистике

Студент: Исмоилов Шахзод
Преподаватель: Иван Канонов
Группа: Р3207
Дата: 25 мая 2025 г.

Содержание

1	Задание 1	2
2	Задание 2	5
	Задание 3	6

1 Задание 1

Условие

В файле `iris.csv` представлены данные о параметрах различных экземпляров цветка ириса. Определить количество экземпляров каждого вида, рассчитать выборочные характеристики (среднее, дисперсия, медиана, квантиль порядка $2/5$) для суммарной площади чашелистика и лепестка для всей выборки и по видам. Построить 5 графиков: ЭФР (общая), ЭФР по видам, гистограмма (общая), гистограмма по видам, box-plot по видам.

См. код: <https://github.com/...>

Графики




Рис. 1: Эмпирическая функция распределения — вся выборка




Рис. 2: Эмпирическая функция распределения по видам




Рис. 3: Гистограмма — вся выборка




Рис. 4: Гистограмма по видам




Рис. 5: Box-plot по видам

2 Задание 2

Предположение о законе распределения

Предполагается нормальное распределение суммарной площади:

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

Оценка параметров

Метод моментов

$$\hat{\mu} = \bar{X} = 23.6169, \quad \hat{\sigma}^2 = S^2 = 47.9095, \quad \hat{\sigma} = \sqrt{47.9095} \approx 6.923.$$

Метод максимального правдоподобия

Функция правдоподобия:

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(X_i - \mu)^2}{2\sigma^2}\right).$$

Решая уравнения, получаем:

$$\hat{\mu}_{ML} = \bar{X}, \quad \hat{\sigma}_{ML}^2 = \frac{n-1}{n} S^2 \approx 47.5833.$$

Свойства оценок

- Несмещённость: $E[\hat{\mu}] = \mu$, $E[S^2] = \sigma^2$.
- Состоятельность: $\hat{\mu} \rightarrow \mu$, $S^2 \rightarrow \sigma^2$ при $n \rightarrow \infty$.
- Эффективность (асимптотическая): $\hat{\mu}$ достигает границы Рао–Крамера.
- Асимптотическая нормальность: $\sqrt{n}(\hat{\mu} - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2)$.

Теоретические характеристики

$$\begin{aligned} \text{Bias}(\hat{\mu}) &= 0, \quad \text{Var}(\hat{\mu}) = \frac{\sigma^2}{n}, \\ \text{Bias}(\hat{\sigma}_{ML}^2) &= -\frac{\sigma^2}{n}, \quad \text{Var}(S^2) = \frac{2\sigma^4}{n-1}, \\ \text{MSE}(\hat{\mu}) &= \frac{\sigma^2}{n}, \\ I(\mu) &= \frac{n}{\sigma^2}, \quad I(\sigma^2) = \frac{n}{2\sigma^4}. \end{aligned}$$

Задание 3

Постановка задачи

Пусть выборка $X_1, \dots, X_n$ поступает из нормального распределения

$$X_i \sim \mathcal{N}(\mu, \sigma^2), \quad \mu = 23.86, \quad \sigma^2 = 241.89.$$

Для каждого объёма выборки

$$n \in \{10, 20, 30, \dots, 100\}$$

проводится $M = 1000$ независимых экспериментов:

1. Сгенерировать выборку размера n .
2. Вычислить несмещённые оценки

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$

По результатам M повторов для каждой оценки $\theta \in \{\hat{\mu}, \hat{\sigma}^2\}$ рассчитываются:

$$E[\hat{\theta}], \quad \text{Bias}(\hat{\theta}) = E[\hat{\theta}] - \theta_{\text{true}},$$

$$\text{Var}(\hat{\theta}), \quad \text{MSE}(\hat{\theta}) = \text{Bias}(\hat{\theta})^2 + \text{Var}(\hat{\theta}).$$

Результаты моделирования




Рис. 6: Сводная таблица статистик оценок $\hat{\mu}$ и $\hat{\sigma}^2$ для разных n .




Рис. 7: Гистограммы и KDE распределения оценки $\hat{\mu}$ при различных объёмах выборки n .

Краткие выводы

- Оценка $\hat{\mu}$ является несмещённой ($E[\hat{\mu}] \approx 23.86$) и состоятельной: её дисперсия и MSE быстро уменьшаются при росте n , что подтверждается сужением гистограмм вокруг истинного μ (рис. 7).
- Оценка $\hat{\sigma}^2$ также несмещённая ($E[\hat{\sigma}^2] \approx 241.89$) и состоятельная: при больших n распределение $\hat{\sigma}^2$ концентрируется ближе к истинному значению (рис. 8), хотя имеет больший разброс, чем $\hat{\mu}$.
- Обе оценки подтверждают центральную предельную теорему и асимптотическую нормальность при достаточном объёме выборки.

См. код: <https://github.com/...>


```

=== Статистика оценок  $\hat{\mu}$  и  $\hat{\sigma}^2$  по объёму выборки ===

```

n	Среднее $\hat{\mu}$	Смещение $\hat{\mu}$	Дисперсия $\hat{\mu}$	MSE $\hat{\mu}$	Среднее $\hat{\sigma}^2$	Смещение $\hat{\sigma}^2$	Дисперсия $\hat{\sigma}^2$	MSE $\hat{\sigma}^2$
10	23.737874	-0.122126	24.554780	24.569615	245.682608	3.792608	12691.532303	12705.916178
20	23.891870	0.031870	12.396587	12.397602	243.827020	1.937020	6302.530605	6306.282652
30	23.781345	-0.078655	8.104484	8.110671	239.362880	-2.527120	3925.542877	3931.929213
40	23.817082	-0.042918	6.082775	6.084617	240.486199	-1.403801	3245.241966	3247.212622
50	23.930693	0.070693	4.997337	5.002334	240.913503	-0.976417	2504.493783	2505.447174
60	23.941269	0.081269	3.994834	4.001438	244.263295	2.373295	1923.036494	1928.669024
70	23.912321	0.052321	3.391655	3.394393	242.435136	0.545136	1576.646252	1576.943425
80	23.837475	-0.022525	2.836645	2.837153	244.171290	2.281290	1651.506592	1656.710877
90	23.835084	-0.024916	2.511849	2.512470	242.384460	0.494460	1334.607508	1334.851999
100	23.845680	-0.014320	2.443699	2.443984	241.514005	-0.375995	1141.538438	1141.679810

Рис. 8: Гистограммы и KDE распределения оценки $\hat{\sigma}^2$ при различных объёмах выборки n .