

Санкт-Петербургский государственный университет

Факультет прикладной математики и компьютерных наук

Лабораторная работа по математической статистике

Тема: Статистический анализ данных о
недвижимости в Сиэтле

Студент: Исмоилов Шахзод

Преподаватель: Иван Канонов

Группа: Р3207

Дата: 28 мая 2025 г.

Содержание

1	Введение	2
2	Описание данных	2
3	Проверка распределения цены	2
3.1	Формулировка задачи	2
3.2	Методы	2
3.3	Результаты	3
4	Сравнение распределений старого и нового фонда	4
4.1	Формулировка задачи	4
4.2	Методы	4
4.3	Результаты	4
5	Анализ корреляции цены и площади	4
5.1	Формулировка задачи	4
5.2	Методы	5
5.3	Результаты	5
6	Вывод программы	6
7	Ссылка на репозиторий с кодом	6

1 Введение

В данной работе проведён статистический анализ данных о ценах на недвижимость в районе Сиэтла. Цель — исследовать распределение цен, сравнить распределения старого и нового фонда, а также проверить наличие зависимости между жилой площадью и ценой.

2 Описание данных

Данные содержат около 21 тысячи записей с информацией о недвижимости, включая цену (`price`), жилую площадь (`sqft_living`), год постройки (`yr_built`) и другие параметры. Для анализа были выбраны переменные, непосредственно влияющие на исследуемые гипотезы.

3 Проверка распределения цены

3.1 Формулировка задачи

Проверить гипотезу:

H_0 : цены распределены согласно логнормальному закону

H_1 : цены не распределены согласно логнормальному закону

с уровнем значимости $\alpha = 0.05$.

3.2 Методы

1. **Критерий Колмогорова-Смирнова (К-С).** Определяется статистика:

$$D = \sup_x |F_n(x) - F_0(x)|$$

где F_n — эмпирическая функция распределения, F_0 — функция распределения логнормального закона. Критическое значение при $\alpha = 0.05$ рассчитывается как:

$$D_{\text{crit}} = \frac{1.36}{\sqrt{n}}$$

2. **Хи-квадрат тест согласия.** Данные разбиваются на $k = 20$ интервалов. Рассчитывается статистика:

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

где O_i — наблюдаемая частота в интервале i , E_i — ожидаемая по логнормальному закону частота, учитывая оценённые параметры. Степени свободы:

$$df = k - 1 - m$$

где $m = 3$ — число параметров (форма, сдвиг, масштаб).

3.3 Результаты

- $D = 0.0260$, $D_{\text{crit}} = 0.0093$, $p = 4.19 \times 10^{-13}$ — К-С тест отвергает H_0 .
- $\chi^2 = 3750.09$, $p < 10^{-16}$ — хи-квадрат тест также отвергает H_0 .

Отсюда следует, что логнормальное распределение плохо описывает распределение цены.




Рис. 1: Гистограмма распределения цены с наложенной плотностью логнормального распределения

4 Сравнение распределений старого и нового фонда

4.1 Формулировка задачи

Сравнить распределения цен в старом (построенные более 30 лет назад) и новом фонде:

$$H_0 : F_{\text{old}} = F_{\text{new}}$$

$$H_1 : F_{\text{old}} \neq F_{\text{new}}$$

4.2 Методы

- Двухвыборочный критерий Колмогорова-Смирнова.
- Хи-квадрат тест по гистограммам, нормированным и отфильтрованным от нулевых бин.

4.3 Результаты

- К-С тест: $D = 0.1287$, $p \approx 1.67 \times 10^{-73}$ — гипотеза отвергается.
- Хи-квадрат тест: $\chi^2 = 608.20$, $p \approx 3.65 \times 10^{-125}$ — гипотеза отвергается.

Это указывает на статистически значимые различия в распределениях цен.

5 Анализ корреляции цены и площади

5.1 Формулировка задачи

Проверить, есть ли связь между жилой площадью и ценой:

$$H_0 : \rho = 0$$

$$H_1 : \rho \neq 0$$

где ρ — коэффициент корреляции.

5.2 Методы

- Коэффициент корреляции Пирсона:

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$

Значимость проверялась с помощью t -статистики:

$$t = r \sqrt{\frac{n-2}{1-r^2}}$$

- Коэффициент корреляции Спирмена — непараметрическая мера монотонной зависимости.

5.3 Результаты

- $r = 0.7020$, $t = 144.92$, $p < 10^{-16}$ — значимая положительная корреляция.
- Спирмен: $\rho = 0.6442$, $p < 10^{-16}$ — подтверждение связи.



Рис. 2: Диаграмма рассеяния цены от жилой площади

6 Вывод программы

```
KS-test вручную: D = 0.0260, p-value = 4.1904e-13
Критическое значение KS: 0.0093
Chi2-test: chi2 = 3750.09, p-value = 0.0000e+00

1. Проверка распределения цены:
- KS-тест отвергает гипотезу (p=4.1904e-13 <= 0.05)
- Chi2-тест отвергает гипотезу (p=0.0000e+00 <= 0.05)

2. Проверка равенства распределений цены (KS тест scipy): D = 0.1287, p = 1.6650e-73
Chi2-тест (нормированный и отфильтрованный): chi2 = 608.20, p = 3.6474e-125
- KS тест отвергает гипотезу о равенстве распределений
- Chi2 тест отвергает гипотезу о равенстве распределений

3. Корреляция Пирсона (вручную): r = 0.7020, t = 144.9204, p = 0.0000e+00
Корреляция Спирмена (scipy): rho = 0.6442, p = 0.0000e+00
- Отвергаем H0, существует значимая корреляция между площадью и ценой
```

Рис. 3: Вывод программы с результатами тестов и корреляции

7 Ссылка на репозиторий с кодом

Исходный код всех вычислений и построения графиков доступен по ссылке:

<https://github.com/inertmao/itmo/tree/main/C24S/MathStat/lab3>