

Лабораторная работа №4 по математической статистике

Задания 1 и 2

Студент: Исмоилов Шахзод

28 мая 2025 г.

Содержание

1	Задание 1: Линейная регрессия на данных о продажах автомобилей	2
1.1	Описание задачи	2
1.2	Результаты	3
1.3	Вывод	4
1.4	Вывод	4
2	Задание 2: Однофакторный дисперсионный анализ на данных об ирисах	6
2.1	Описание задачи	6
2.2	Методика	6
2.3	Результаты	6
2.4	Вывод	7
2.5	Вывод	7
3	Ссылки на исходный код	8

1 Задание 1: Линейная регрессия на данных о продажах автомобилей

1.1 Описание задачи

В файле `cars93.csv` представлены данные о продаже различных автомобилей.

Требуется построить линейную модель зависимости цены автомобиля от следующих факторов:

- Расход топлива в городе (`MPG.city`)
- Расход топлива на шоссе (`MPG.highway`)
- Мощность двигателя (`Horsepower`)

Необходимо:

1. Оценить коэффициенты линейной модели вместе с свободным членом.
2. Вычислить остаточную дисперсию.
3. Построить доверительные интервалы для коэффициентов.
4. Вычислить коэффициент детерминации R^2 .
5. Проверить гипотезы:
 - Чем больше мощность — тем выше цена.
 - Цена зависит от расхода топлива в городе.
 - Гипотеза H_0 : коэффициенты при расходе в городе и на шоссе одновременно равны нулю.
6. Проверить нормальность остатков модели.
7. Построить график реальных и предсказанных значений цены.

1.2 Результаты

По результатам построенной модели получены следующие ключевые показатели:

- Коэффициенты при переменных и свободный член:
 - Свободный член: 6.6887
 - Расход в городе (`MPG.city`): -0.0386
 - Расход на шоссе (`MPG.highway`): -0.1789
 - Мощность (`Horsepower`): 0.1313
- Остаточная дисперсия: (не указана напрямую, но можно взять `model.mse_resid` из кода)
- Доверительные интервалы для коэффициентов:
 - Свободный член: [-5.210, 18.588]
 - `MPG.city`: [-0.748, 0.671]
 - `MPG.highway`: [-0.884, 0.526]
 - `Horsepower`: [0.099, 0.163]
- Коэффициент детерминации R^2 : 0.630
- Проверка гипотез:
 - Связь мощности с ценой — гипотеза подтверждена ($p < 0.001$).
 - Влияние расхода в городе — гипотеза не подтверждена ($p = 0.914$).
 - Совместная проверка коэффициентов при `MPG.city` и `MPG.highway`:
$$F = 1.04, \quad p = 0.359$$
— гипотеза не отвергнута.
- Нормальность остатков — проверка:
 - Тест Omnibus: p-value = 0.000
 - Тест Jarque-Bera: p-value 1.13e-74
 - Вывод: остатки распределены ненормально.

1.3 Вывод

Построена линейная модель зависимости цены автомобиля от расхода топлива в городе, расхода на шоссе и мощности двигателя.

- Коэффициент детерминации $R^2 = 0.630$ указывает, что модель объясняет 63% вариации цены.
- Коэффициент при мощности положителен и статистически значим ($p < 0.001$), что подтверждает влияние мощности на цену.
- Коэффициенты при расходе топлива в городе и на шоссе незначимы ($p > 0.6$ и $p > 0.9$ соответственно), следовательно, статистически значимого влияния на цену не оказывают.
- F-тест проверки гипотезы о равенстве нулю коэффициентов при расходе в городе и на шоссе показал:

$$F = 1.04, \quad p = 0.359 > 0.05$$

Гипотезу отвергнуть нельзя — совместное влияние этих факторов на цену не подтверждается.

- Тесты нормальности остатков (Omnibus и Jarque-Bera) показали значительные отклонения от нормальности, что может снижать надёжность выводов модели.

1.4 Вывод

Построена линейная модель зависимости цены автомобиля от расхода топлива в городе, расхода на шоссе и мощности двигателя.

- Коэффициент детерминации $R^2 = 0.630$ указывает, что модель объясняет 63% вариации цены.
- Коэффициент при мощности положителен и статистически значим ($p < 0.001$), что подтверждает влияние мощности на цену.
- Коэффициенты при расходе топлива в городе и на шоссе незначимы ($p > 0.6$ и $p > 0.9$ соответственно), следовательно, статистически значимого влияния на цену не оказывают.

- F-тест проверки гипотезы о равенстве нулю коэффициентов при расходе в городе и на шоссе показал:

$$F = 1.04, \quad p = 0.359 > 0.05$$

Гипотезу отвергнуть нельзя — совместное влияние этих факторов на цену не подтверждается.

- Тесты нормальности остатков (Omnibus и Jarque-Bera) показали значительные отклонения от нормальности (очень низкие p -значения), что может снижать надёжность выводов модели.

Данный анализ свидетельствует, что из выбранных факторов на цену существенно влияет только мощность двигателя.




Рис. 1: График реальных и предсказанных значений цены автомобилей

2 Задание 2: Однофакторный дисперсионный анализ на данных об ирисах

2.1 Описание задачи

В файле `iris.csv` представлены данные об ирисах трёх подвидов.

Фактор: подвид ириса (**Species**).

Зависимая переменная: суммарная площадь чашелистика и лепестка, рассчитанная как:

$$\text{TotalArea} = \text{Sepal.Length} \times \text{Sepal.Width} + \text{Petal.Length} \times \text{Petal.Width}$$

Требуется проверить гипотезу равенства средних значений **TotalArea** между подвидами с помощью однофакторного дисперсионного анализа (ANOVA).

2.2 Методика

Выполнен классический однофакторный дисперсионный анализ:

- Вычислены межгрупповая и внутригрупповая сумма квадратов.
- Определены степени свободы.
- Рассчитаны средние квадраты.
- Рассчитана статистика F .
- Определено критическое значение F при уровне значимости $\alpha = 0.05$.
- Сравнение статистики с критическим значением для принятия решения.

2.3 Результаты

- Значение F -статистики: 133.2972
- Критическое значение F при $\alpha = 0.05$: 3.0576
- p -значение: 1.1102e-16

2.4 Вывод

Так как $F = 133.2972 > F_{\text{крит}} = 3.0576$ и $p = 1.1102 \times 10^{-16} < 0.05$, нулевая гипотеза о равенстве средних значений отвергается. Следовательно, существуют статистически значимые различия в суммарной площади чашелистика и лепестка между подвидами ириса.

2.5 Вывод

Так как $F > F_{\text{крит}}$ (или $p < 0.05$), нулевая гипотеза о равенстве средних значений отвергается. Следовательно, существуют статистически значимые различия в суммарной площади чашелистика и лепестка между подвидами ириса.

3 Ссылки на исходный код

Весь используемый код для решения заданий доступен в репозитории GitHub:

<https://github.com/inertmao/itmo/tree/main/C24S/MathStat/lab4>